



华中科技大学学报(自然科学版)

Journal of Huazhong University of Science and Technology(Natural Science Edition)

ISSN 1671-4512,CN 42-1658/N

《华中科技大学学报(自然科学版)》网络首发论文

题目: 动态权值自适应分配的 LSTM 洪水演进方法
作者: 姜维龙, 陈璐, 易彬, 康乐
DOI: 10.13245/j.hust.250125
收稿日期: 2025-03-28
网络首发日期: 2025-09-16
引用格式: 姜维龙, 陈璐, 易彬, 康乐. 动态权值自适应分配的 LSTM 洪水演进方法
[J/OL]. 华中科技大学学报(自然科学版). <https://doi.org/10.13245/j.hust.250125>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

DOI: 10.13245/j.hust.250125

动态权值自适应分配的 LSTM 洪水演进方法

姜维龙¹ 陈璐^{1, 2} 易彬¹ 康乐³

(1. 华中科技大学土木与水利工程学院, 湖北武汉 430074; 2. 西藏农牧学院水利土木工程学院, 西藏林芝 860000; 3. 鄂尔多斯水文水资源分中心, 内蒙古鄂尔多斯 017000)

摘要为提高洪水演进的模拟精度, 增强模型对洪峰及其相邻时段流量变化的捕捉能力, 提出了基于动态权值自适应分配的长短期记忆网络(LSTM)洪水演进方法。首先, 建立基于洪水子序列预测误差值正则化的动态权值分配矩阵; 然后, 将动态权值嵌入至均方误差损失中, 提出了一种学习权重自适应的模型优化策略, 使模型对高流量时段的洪水序列学习权重自适应增强, 而低流量时段的洪水序列学习权重自适应衰减。为验证本文方法的有效性, 选取汉江下游皇庄至仙桃河段作为研究区域开展实例研究。结果表明: 与传统 LSTM 方法相比, 本文方法在洪峰及高流量时段模拟精度提升显著且全洪水过程表现更为稳定, 显著提升了整体洪水演进效果。

关键词 洪水演进; 深度学习; 长短期记忆网络(LSTM); 动态权值; 自适应分配

中图分类号 TV122; TP183 文献标志码 A

Dynamic weight adaptive allocation-based LSTM method for flood routing

JIANG Weilong¹ CHEN Lu^{1,2} YI Bin¹ KANG Le³

(1. School of Civil and Hydraulic Engineering, Huazhong University of Science and Technology, Wuhan 430074, China; 2. College of Water Conservancy and Civil Engineering, Xizang Agriculture and Animal Husbandry University, Linzhi 860000, China; 3. Erdos Hydrological and Water Resources Sub-Center, Erdos 017000, China)

AbstractTo enhance the simulation accuracy of flood routing and improve the model's capability to capture flood peaks and adjacent flow variations, a dynamic weight adaptive allocation-based long short-term memory(LSTM) method for flood routing is proposed in this study. First, a dynamic weight allocation matrix is established based on the regularization of prediction error values for flood sub-sequences. Subsequently, the dynamic weights are incorporated into the mean squared error (MSE) loss function to formulate a model optimization strategy with adaptive learning weights. Such strategy enables the model to adaptively amplify learning weights for high-flow periods while attenuating those for low-flow periods. To validate the proposed method, a case study was carried out at the lower reaches of the Hanjiang River from Huangzhuang to Xiantaohydrologic station. Results demonstrated that, compared to typical LSTM approaches, the proposed method significantly improved simulation accuracy for flood peaks and high-flow periods while exhibiting more stable performance across the entire flood process, markedly enhancing the overall effectiveness of flood routing.

Key words flood routing; deep learning; long short-term memory (LSTM); dynamic weight; adaptive allocation

洪水灾害严重威胁人类的生产活动安全, 精确模拟河道洪水演进过程, 对于流域防洪调度、灾害风险评估以及应急响应策略制定具有重要意义^[1-2]。近年来, 在大数据技术快速发展的背景下, 以深度学习为代表的驱动模型为洪水预测领域提供了

新的学习范式和途径^[3-5]。其中, LSTM 作为循环神经网络的一种重要变体模型, 通过引入记忆单元结构, 有效克服了传统循环神经网络存在梯度弥散或梯度爆炸的问题, 擅长捕捉序列数据中的时间依赖性与长期时序规律^[6]。凭借强大的长程依赖关系建

收稿日期 2025-03-28

作者简介姜维龙(2003-), 男, 博士研究生; 陈璐(通信作者), 教授, E-mail: chen_lu@hust.edu.cn.

基金项目国家自然科学基金联合基金项目(U24B20105)

模能力,以 LSTM 为代表的时序深度学习模型能够隐式地学习上下游洪水过程间的非线性动态关联特征;同时,其计算效率高且模型拓展性强,在处理洪水时序数据方面展现出显著优势^[7]。

LSTM 模型在降雨预报、径流预报、洪水预报等时序任务中受到诸多学者的广泛关注^[8-10]。黄靖涵等^[11]构建了基于 LSTM 等多种深度学习模型驱动的集合优化模型,用于东津沱等水文站点的洪水预测;Roy 等^[12]针对传统 LSTM 无法精确预测多步预测时的输出序列,采用了 seq2seqLSTM 替代模型对沿海城市街道规模的实时洪涝进行多尺度预测;Zhang 等^[13]为增强 LSTM 对降雨数据和动态径流的特征捕捉能力,提出了一种基于注意力机制的长短期记忆网络并用于中国深圳市三个城市洪涝灾害热点区域的洪水预测。

洪水演进过程模拟的精度主要取决于对洪峰及其邻近高流量区间的准确刻画^[14-15]。然而,传统基于 LSTM 的洪水演进模型通常采用均方误差(mean squared error, MSE)作为全局损失函数,此类基于整体误差最小化的优化策略易导致模型过度拟合低流量区间^[16,17]。此外,由于低流量样本在时间序列中占比较大,模型训练过程中会系统性偏向于低流量水文特征提取,致使洪峰及其邻近高流量时段洪水预报精度偏低。

针对上述问题,本研究提出了一种基于动态权值自适应分配机制的 LSTM 洪水演进模型,用于增强洪峰及其相邻时段的洪水模拟能力。在模型训练过程中通过一种动态权值自适应分配机制来动态调整不同时间步的洪水样本对损失函数的贡献权重,提升高流量时段的学习权重而降低模型对易学习的低流量时段的关注。在不牺牲模型整体效率的前提下,显著提升洪水演进模型对洪峰流量及高流量区间的刻画精度,为防洪决策等提供更为可靠的实时预报支持。

1 动态权值自适应分配的 LSTM 神经网络洪水演进模型

1.1 基于 LSTM 的洪水演进模型

基于数据驱动的洪水演进方法将河道区间视为一个系统,通过建立深度学习模型学习数据间的映射关系 $f(\cdot)$,使其能够依据上游流量序列 Q^u 推求下游流量序列 Q^d 的变化趋势,

$$Q^d = f(Q^u), (1)$$

式中,映射关系 $f(\cdot)$ 是由 LSTM 模型内部的门控机制学习的上下游洪水流量变化关系。一般地, LSTM 的核心组成有输入门、遗忘门、输出门及细胞状态,各部件间通过逻辑门控制时序信息的流动,实现时序预测。

a 输入门。输入门由两部分组成

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i); (2)$$

$$\bar{C}_t = \tanh(W_C[h_{t-1}, x_t] + b_C), (3)$$

式中: $\sigma(\cdot)$ 为 Sigmoid 激活函数; $\tanh(\cdot)$ 为 tanh 激活函数; x_t 为当前时间步 t 的时序输入; h_{t-1} 为前一个时间步的隐藏状态; i_t 为输入门的输出; $\bar{C}_t$ 为待选值; W_i 和 W_C 为对应的权重矩阵; b_i 和 b_C 分别为对应的偏置项。式(2)决定新信息的更新量,式(3)决定信息的数值。

b 遗忘门。遗忘门的作用是决定从细胞状态中应该舍弃的时序信息部分

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f), (4)$$

式中: W_f 为遗忘门对应的权重矩阵; b_f 为其偏置项。

c 细胞状态更新。细胞状态主要用于更新由输入门和遗忘门结合的时序信息

$$C_t = f_t \odot C_{t-1} + i_t \odot \bar{C}_t, (5)$$

式中: C_t 为当前时间步的细胞状态; C_{t-1} 为前一个时间步的细胞状态; $\odot$ 为 Hadamard 乘积。

d 输出门。输出门的作用是决定细胞状态的特定部分输出到下一时间步中

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o); (6)$$

$$h_t = o_t \odot \tanh(C_t), (7)$$

式中: o_t 为输出门的输出; h_t 为当前时间步的隐藏状态; W_o 为权重矩阵; b_o 为对应偏置项。

1.2 动态权值自适应分配机制

因传统 LSTM 洪水演进模型采用全局优化策略,致使模型对洪峰及其相邻时段的洪水预测精度不足。本研究提出一种基于洪水子序列预测误差的动态权值自适应分配机制。首先,通过正则化各洪水子序

列的预测值与实测值之间的误差，在训练阶段动态计算各子序列的权重系数并构建动态权值分配矩阵；然后，将动态权值分配矩阵局部集成至基于均方误差损失函数中，实现高流量学习权重的自适应增加与低流量学习权重的自适应减少，从而提升洪水子序列的预测精度，优化洪水全过程演进效果。

为从历史洪水场次中提取有效时序信息，历史的上游洪水流量序列 Q^u 将被划分为多个长度为 k 的子序列 Q_i^u

$$Q^u = \{Q_i^u\}_{i=1}^N, Q_i^u = \{q_{i,t}^u, q_{i,t+1}^u, \dots, q_{i,t+k-1}^u\}, \quad (8)$$

式中： N 为子序列个数； Q_i^u 为上游洪水子序列； $q_{i,t}^u$ 为上游的第 i 个子序列在第 t 个时段的洪水流量值。

所有子序列 Q_i^u 经神经网络模型预测输出下游流量 Q^d 在第 $(t+k)$ 个时段的洪水预测流量值 $\hat{q}_{i,t+k}^d$ ，根据求和所有真实值 $q_{i,t+k}^d$ 与预测值 $\hat{q}_{i,t+k}^d$ 间的均方误差作为损失约束，进一步反向传播整个网络，以便网络参数更新，计算损失 L_{mse}

$$\hat{q}_{i,t+k}^d = \phi(Q_i^u); \quad (9)$$

$$L_{mse} = \frac{1}{N} \sum_{i=1}^N (\hat{q}_{i,t+k}^d - q_{i,t+k}^d)^2, \quad (10)$$

式中 $\phi(\cdot)$ 为 LSTM 模型提取时序特征后的全连接网络预测部分。

由式(10)可知：传统的均方误差损失会平等地学习每个子序列的预测误差，优化器则根据误差大小调整网络参数，减小整体误差。然而，低流量时段样本占比大，数值较小且波动较为平缓，模型往往能够充分学习到低流量水文特征，并给出较为准确的预测结果。反之，洪峰及其相邻时段的洪水样本占比小，数值较大且波动较为显著。在全局优化的策略下，传统 LSTM 深度学习模型在前期学习中无法有效捕捉洪峰及其相邻时段的流量变化趋势，最终导致整体洪水预测性能不佳。为此，提出动态权值分配模块 $\phi_e(\cdot)$ ，对每一个子序列 Q_i^u ，计算基于预测误差 R_i 的动态权值 W_i

$$R_i = \|\phi_e(Q_i^u) - q_{i,t+k}^d\|_F^2; \quad (11)$$

$$W_i = \frac{R_i - R_{\min}}{R_{\max} - R_{\min}}, \quad (12)$$

式中： $\phi_e(Q_i^u)$ 为 Q_i^u 经 $\phi_e(\cdot)$ 的预测输出； $\|\cdot\|_F^2$ 为二范

数； $R_{\max}$ 为最大预测误差值； $R_{\min}$ 为最小预测误差值。

预测误差越大的洪水子序列其对应的学习权重值则越大，反之则越小。为此，进一步将动态权值集成至模型损失函数中，使模型能够自适应地增强高流量区间的洪水特征学习，即赋予较大的权重系数；同时，自适应地降低对低流量时段洪水子序列的关注度，即分配较小的权重系数，损失计算

$$L_{mse}^* = \frac{1}{N} \sum_{i=1}^N W_i (\hat{q}_{i,t+k}^d - q_{i,t+k}^d)^2. \quad (13)$$

由式(13)可知：对每个子序列的预测误差进行正则化后得到的权值，将重新分配给改进的均方差损失 L_{mse}^* ，后续模型在每次迭代优化训练中，将更加关注于预测误差数值波动较大的子序列，从而在洪水演进中有效地拟合洪峰及其相邻时段的洪水。此外，该机制是一种直接可嵌入网络的模块，通过与常规基于 LSTM 网络的全连接预测层进行参数共享，实现端到端的精准洪水演进。

1.3 改进洪水演进模型框架

基于动态权值自适应分配机制，本研究将其与 LSTM 相结合，构建改进的 LSTM 洪水演进模型。图 1 展示了该模型的整体洪水演进流程，具体建模过程如下。

a 数据处理。首先对洪水时序数据进行数据集划分，将其分为训练集和测试集，随后采用滑动窗口采样技术提取洪水子序列，并通过批处理操作构建模型训练和测试所需的数据批次；

b 网络搭建。构建 LSTM 神经网络和动态权值分配模块，同时对网络中的神经元进行参数随机初始化；

c 动态权值自适应分配。依次将训练集中的洪水子序列输入模型，依据式(11)~(13)计算每个洪水子序列的动态权值并将其加入模型损失函数中，随后损失通过 Adam 优化器进行反向传播并更新网络参数；

d 模型训练。随着训练迭代次数的增加，当模型损失函数值收敛至稳定状态时，保存最优模型参数；

e 模型测试。在模型测试阶段，将训练所得的最优模型参数导入测试框架，随后输入测试集内的洪水子序列数据进行前向计算，输出预测结果并进行模型性能评估。




图1 整体洪水演进流程图

1.4 评价指标

为评估模型有效性,采用纳什效率系数(E_{nse})、洪峰相对误差(E_{rep})以及洪量相对误差(E_{rev})作为模型评价指标。具体计算公式如下

$$E_{nse} = 1 - \frac{\sum_{i=1}^N (\hat{q}_{i,t+k}^d - q_{i,t+k}^d)^2}{\sum_{i=1}^N (q_{i,t+k}^d - \bar{q}^d)^2}; \quad (14)$$

$$E_{rep} = \frac{\hat{q}_p - q_p}{q_p} \times 100\%; \quad (15)$$

$$E_{rev} = \frac{\sum_{i=1}^N \hat{q}_{i,t+k}^d - \sum_{i=1}^N q_{i,t+k}^d}{\sum_{i=1}^N q_{i,t+k}^d} \times 100\%, \quad (16)$$

式中: $\bar{q}^d$ 为实测洪水流量均值; $\hat{q}_p$ 为预测洪峰流量值; q_p 为实测洪峰流量值。


2 应用研究

2.1 研究区域概况


汉江作为长江中游最大的一条支流,干流全长1577km,流域面积达15.9万 km^2 。而汉江下游流域以钟祥市为分界点,属于副热带季风气候区,流域内水系发达、湖泊众多且联通性复杂,流经汉江平原,具备平原河网典型水文及水资源特征。

选取汉江下游皇庄站至仙桃站区间河道为研究对象,该区间河道自上而下蜿蜒曲折且河道宽度逐


步紧缩,导致河道泄洪能力随缩窄而显著下降,易产生洪水威胁。其中,皇庄站位于湖北省钟祥市郢中镇,仙桃站位于湖北省仙桃市,皇庄至仙桃河道全长为225 km。如图2所示,以皇庄、仙桃水文站2018,2020和2021年真实汛期时段的连续洪水过程资料作为数据基础,时间尺度为1 h;数据集中包含不同量级的洪水场次、单峰、双峰以及多峰的洪水事件,保障了模型学习洪水特征的丰富性。最后,以2018和2020年洪水数据用于模型训练,2021年洪水数据用于模型测试。



(a)2018年4月15日9点至9月8日13点



(b)2020年6月16日8点至9月10日23点



(c) 2021 年 8 月 7 日 0 点至 10 月 31 日 14 点

图 2 2018、2020 及 2021 年汛期连续洪水过程

2.2 结果与分析

2.2.1 模型参数设置

为保证模型对比试验的公平性与一致性, 本文方法与 LSTM 方法均为堆叠两层 LSTM 单元, 每层单元数量为 128。预测部分均为三层全连接层, 各层的输入输出分别为(128, 128)、(128, 32)和(32, 1)。在 LSTM 层与预测层间有一层失活层, 失活率的大小为 0.3。洪水序列经滑动窗口技术进行采样, 采样窗口大小设置为 48, 即 $k=48$; 模型参数优化器为 Adam, 学习率的大小为 0.001; 训练样本集的批次大小为 32; 训练迭代次数为 200 次; 为减小随机误差影响, 所有试验结果为 10 次反复试验求取平均值。

2.2.2 模型损失收敛对比

模型损失收敛过程可反映其参数更新的快慢与预测性能是否稳定。随着模型迭代次数增加, 模型损失值越小且数值波动幅度越小, 则该模型参数收敛且综合性能越好。图 3 给出了训练期间传统 LSTM 和本文方法在训练集上的模型损失收敛曲线对比。在模型训练期间, LSTM 的损失最终在 0.01 附近, 且损失值大小波动较为明显, 而本文方法能够更快速且稳定地进行模型训练, 模型损失数值低于 0.005 且损失值大小波动较为稳定, 证明了所提动态权值自适应分配机制能够有效改善模型对洪水子序列流量变化趋势的捕捉能力, 并提高整体的洪水演进性能。





图 3 模型损失收敛曲线对比


2.2.3 应用结果分析

a. 整体连续洪水过程线对比

基于训练数据训练至模型收敛后, 对测试集中 2021 年的连续洪水过程进行模拟验证, 并将其划分为两场大洪水分别进行展示。图 4 给出了两场大洪水的洪水过程线, 从皇庄站和仙桃站的实测洪水过程可知, 其中涵盖了不同量级的洪水事件, 保障了模型在遭遇不同量级洪水事件时, 同样能够有效地进行洪峰模拟。



(a) 测试集中的连续洪水过程 1



(b) 测试集中的连续洪水过程 2

图 4 LSTM 和本文方法在测试集中的 2 场连续洪水过程线对比

本文方法在低流量阶段的演进效果与 LSTM 基本一致, 但对洪峰及其相邻时段洪水模拟效果有显著提升。值得注意的是, 皇庄站的流量数值及洪水量级均远高于仙桃站, 且两站洪水流量变化过程之间在部分时段表现出明显的非线性关系。例如, 皇庄站的洪水过程在部分时段呈现陡涨陡落的特征, 而相同时段内仙桃站的洪水过程则相对平缓。正是这种复杂的站间洪水变化关系, 导致 LSTM 与本文方法对仙桃站部分时段洪水过程的模拟均存在不足。尽管如此, 在整体性能上本文方法仍优于传统 LSTM 模型。

表 1 给出了皇庄站的洪水数据演进至仙桃站时, 各模型评价指标结果对比。由表 1 可知: 在仅有皇庄流量数据作为输入条件下, 基于 LSTM 的演进法对于 1 号和 2 号连续洪水过程演进的纳什系数分别

为 0.85 和 0.87；本文方法针对 1 号和 2 号连续洪水过程的纳什系数分别达到了 0.96 和 0.91，提升效果显著。此外，本文方法在洪峰误差和洪量误差指标上均有大幅提升。对于 1 号连续洪水过程，整个过程最大实测洪峰为 8555m³/s，本文方法的最大预测洪峰为 8692m³/s，洪峰误差和洪量误差分别为 1.60% 和 -1.10%，而 LSTM 方法的最大预测洪峰为 7199m³/s，洪峰误差和洪量误差分别为 -15.85% 和 -9.88%。同样，对于 2 号连续洪水过程，本文方法洪峰误差和洪量误差分别为 6.46% 和 1.84%，而 LSTM 方法的洪峰误差和洪量误差分别为 -12.56% 和 -3.99%，演进效果改善显著。这是因为一般基于 LSTM 的洪水演进方法在训练过程中均衡地学习了所有洪水子序列，对样本占比小且数值波动较大的洪峰及高流量时段的流量变化趋势捕捉能力不足，导致洪水时间序列整体全过程信息学习效果欠佳。

表 1 本文方法与对比方法指标评价结果

对比方法	洪水过程	实测洪峰	演进洪峰	E_{rep}	E_{rev}	E_{nse}
LSTM	1	8555	7199	-15.85	-9.88	0.85
	2	8291	7249	-12.56	-3.99	0.87
本文方法	1	8555	8692	1.60	-1.10	0.96
	2	8291	8827	6.46	1.84	0.91

b.不同量级的洪峰模拟对比

如表 2 所示，本文方法相比于传统 LSTM 方法显著改善了洪峰的预测效果。LSTM 模型在 7 号洪峰模拟的效果最好，洪峰误差仅为 0.63%，比本文方法更贴近于真实的洪峰值。然而，需要注意的是，7 号洪峰为表 2 中量级最小的洪峰。相比之下，对于其他量级更大的洪峰，LSTM 模型在多数洪峰处的预测值均低于实际洪峰值。尤其在洪峰量级较大的 3，4，5 号洪峰处，LSTM 模型出现了较大的峰值低估误差，而本文方法在高量级洪峰的预测精度上取得了显著改善。本文方法对应的峰值误差分别减小至 2.76%，-0.12% 和 6.47%。这一结果有力地证实，本文方法能够有效缓解传统 LSTM 模型在洪峰及高流量时段的预测偏差较大的问题。其性能提升主要得益于所提出的动态权值自适应分配机制为高流量时段的洪水学习赋予模型更大的学习权重作为补偿。

表 2 本文方法与 LSTM 在 8 个洪峰处的预测对比

洪峰编号	实测值	预测值	峰值误差/%
------	-----	-----	--------

		LSTM	本文方法	LSTM	本文方法
1	4955	4528	5007	-8.62	1.04
2	7280	6347	6865	-12.82	-5.70
3	8459	7199	8692	-14.90	2.76
4	8555	7159	8545	-16.32	-0.12
5	8291	7249	8827	-12.57	6.47
6	5532	4926	5348	-10.96	-3.33
7	3469	3491	3536	0.63	1.93
8	4127	4064	4216	-1.53	2.16

c.模型计算耗时对比

表 3 进一步给出了本文方法和传统 LSTM 在模型训练耗时和模型测试耗时的对比结果。须说明的是，模型训练耗时为迭代 200 次的完整训练过程所需的时间，而模型测试耗时为测试集上的一次完整测试过程所需的时间。根据表 3 数据可知，在模型训练耗时方面，本文方法耗时略高于 LSTM 模型，这是由于所提出的动态权值自适应分配机制在提升模型精度的同时带来了额外的计算开销。在模型测试耗时方面，两者的测试耗时时间基本保持一致，这是因为测试阶段不引入额外计算，模型直接输出预测结果。考虑到实际应用中模型通常通过离线训练以获得最优参数模型，因此，与本文方法带来洪水演进精度显著提升相比，其导致的适量额外训练耗时是可以接受的；同时重要的是，模型的测试耗时极低，约 0.1 秒，足以满足实际工程应用的时效性需求。

表 3 本文方法与 LSTM 模型计算耗时对比

方法	模型训练耗时/s	模型测试耗时/s
LSTM	164.142	0.103
本文方法	186.344	0.103

综上所述，可证明所提动态权值自适应分配的 LSTM 神经网络洪水演进方法显著提升了对上下游洪水流量间映射关系的学习能力，整体洪水演进过程效果更佳。

3 结论与展望

本研究提出了一种动态权值自适应分配的 LSTM 神经网络用于河道洪水演进，并以汉江下游皇庄至仙桃区间的洪水过程开展实例验证。结果表明本文方法显著提升了洪峰及其相邻时段的模拟精度；与传统 LSTM 方法相比，整体演进结果更贴近于实际洪水过程，全过程洪水演进效果更佳。此外，

还存在以下可改进的方向。

a 所建立的模型仅以流量数据作为输入, 未来研究可在获取降雨过程和区间入流等精细化的数据支撑的基础上, 构造多维特征输入空间以增强样本的表征能力, 探索通过特征增强策略进一步提升模型的洪水演进性能。然而, 输入特征并非越多越好, 冗余和消极特征不仅会增加模型计算负担, 甚至可能导致模型的性能提升不明显甚至下降, 需进一步进行特征工程进行有效的特筛选或互补。

b 采用固定的滑动窗口进行洪水子序列采样, 然而尚未考虑不同时间窗口大小及其包含洪水信息的分布差异对模型输出结果的影响。未来工作可研究窗口尺度的动态选择及其对模型性能的影响规律。

c 本研究侧重于提出自适应权值分配机制来优化模型参数的更新过程, 而各种优化算法可用于考虑优化深度学习中涉及的超参数设置, 进一步提升模型性能。

参考文献

- [1] XU Q S, SHI Y L, BAMBER J L, et al. Large-scale flood modeling and forecasting with FloodCast[J]. *Water Research*, 2024, 264: 122162.
- [2] 童超, 詹晗煜, 崔罡, 等. 融合 ResNet 神经网络与水动力模型的洪水演进快速预测算法[J/OL]. *水资源保护*, 2025: 1-14. (2025-05-20). <https://kns.cnki.net/kcms/detail/32.1356.TV.20250519.1652.031.html>.
- [3] 李承龙, 郭生练, 梁志明, 等. 基于深度学习的长江-洞庭湖流域洪水模拟预报研究[J/OL]. [2025-07-29]. <https://doi.org/10.13243/j.cnki.slxb.20240630>.
- [4] 刘万, 谢帅, 钟德钰, 等. 基于深度学习与 HEC-HMS 模型的小流域暴雨洪水耦合预报[J]. *水利学报*, 2025, 56(3): 364-374.
- [5] 陈璐, 冷致远, 吴常运, 等. 考虑多维评价体系的降水集合预报[J]. *华中科技大学学报(自然科学版)*, 2022, 50(8): 73-78.
- [6] GREFF K, SRIVASTAVA R K, KOUTNÍK J, et al. LSTM: a search space odyssey[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2017, 28(10): 2222-2232.
- [7] LI L, JUN K S. Review of machine learning methods for river flood routing[J]. *Water*, 2024, 16(2): 364.
- [8] 许月萍, 陆豪楠, 于欣廷, 等. 基于深度学习集合预报的水库闸门防洪优化调度[J]. *水科学进展*, 2024, 35(6): 900-913.
- [9] YANG B L, CHEN L, YI B, et al. Evaluating the impact of improved filter-wrapper input variable selection on long-term runoff forecasting using local and global climate information[J]. *Journal of Hydrology*, 2024, 644: 132034.
- [10] 杨鑫, 张建云, 周建中, 等. 基于 ConvLSTM 网络的多源降雨融合方法[J]. *华中科技大学学报(自然科学版)*, 2022, 50(8): 33-39.
- [11] 黄靖涵, 王兆才, 吴俊豪, 等. 基于深度学习集合优化模型的径流区间预测研究[J]. *水利学报*, 2025, 56(2): 240-252.
- [12] ROY B, GOODALL J L, MCSPADDEN D, et al. Forecasting multi-step-ahead street-scale nuisance flooding using a seq2seq LSTM surrogate model for real-time application in a coastal-urban city[J]. *Journal of Hydrology*, 2025, 656: 132697.
- [13] ZHANG L, QIN H P, MAO J Q, et al. High temporal resolution urban flood prediction using attention-based LSTM models[J]. *Journal of Hydrology*, 2023, 620: 129499.
- [14] REINERT J, KLOPRIES E M, SCHÜTTRUMPF H. Meteorological and hydrological data as a basis for issuing flood warnings during the July flood 2021 in Rhineland-palatinate and north Rhine-Westphalia (Germany)[J]. *Journal of Flood Risk Management*, 2025, 18(2): e70078.
- [15] TAHIRI A, CHE D, LADEVEZE D, et al. Network flow and flood routing model for water resources optimization[J]. *Scientific Reports*, 2022, 12(1): 3937.
- [16] ALIZADEH B, GHADERI BAFTI A, KAMANGIR H, et al. A novel attention-based LSTM cell post-processor coupled with Bayesian optimization for streamflow prediction[J]. *Journal of Hydrology*, 2021, 601: 126526.
- [17] FENG D P, LIU J T, LAWSON K, et al. Differentiable, learnable, regionalized process-based models with multiphysical outputs can approach state-of-the-art hydrologic prediction accuracy[J]. *Water Resources Research*, 2022, 58(10): e2022WR032404.